

凸优化学习笔记

陈皦翰 Chen Haohan

最后修改日期：2025 年 8 月 16 日

目录

前言	4
I 基础知识	1
1 课程导入	3
1.1 数学优化概述	3
1.2 最小二乘问题和线性规划简介	4
1.3 凸优化简介	5
1.4 非线性（且非凸的）优化简介	5
1.5 教材大纲	5
1.6 符号表示	6
II 理论基础	7
2 凸集	9
2.1 仿射集和凸集	9
2.2 重要示例	11
2.3 保凸变换	14
2.4 广义不等式（偏序）	17
2.5 分离超平面和支撑超平面	18
2.6 对偶锥和广义不等式	19
3 凸函数	21
3.1 基本属性和示例	21
3.2 保凸变换	23
3.3 共轭函数	26
3.4 拟凸函数	26

4	凸优化问题	28
4.1	优化问题	28
4.2	凸优化问题	32
4.3	线性优化问题	37
4.4	几何优化问题	42
5	对偶性	48
III	应用	49
6	近似和拟合	51
7	统计估计	52
8	几何问题	53

前言

本篇笔记为本人学习斯坦福大学 EE364a 课程的记录，内容包括凸优化的基本概念、定理及其证明等，主要是自己学习过程的记录，也希望能对同样学习这门课程的同学有帮助。

参考书籍：Convex Optimization by Stephen Boyd and Lieven Vandenberghe

Part I

基础知识

Chapter 1

课程导入

本章主要给出数学优化问题的概览，并且着重介绍凸优化的相关知识。在本课程中，我们将会学习如何高效可靠的解决凸优化问题，并且解决一些实例。

1.1 数学优化概述

一般数学优化问题的标准形式为：

$$\begin{aligned} & \text{minimize (使最小化)} && f_0(x) \\ & \text{subject to (满足)} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && g_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

(这里教材上可能有误，没有等式约束) 其中 x 是 $\mathbb{R}^n$ 上的向量，为该优化问题的优化(决策)变量； f_0 是 $\mathbb{R}^n \rightarrow \mathbb{R}$ 上的函数，为目标函数； $f_i(x)$ 是 $\mathbb{R}^n \rightarrow \mathbb{R}$ 上的函数，为不等式约束 (b_i 为该不等式的限制)； $g_i(x)$ 是 $\mathbb{R}^n \rightarrow \mathbb{R}$ 上的函数，为等式约束。这个优化问题表达的就是：在满足所有约束的前提下，找到一个 x 使得目标函数 $f_0(x)$ 最小。

如果一个优化问题中的目标函数以及所有不等式约束均为线性的，那么称该问题为线性优化问题。也就是所有 f_i 满足如下条件：

$$f_i(\alpha x + \beta y) = \alpha f_i(x) + \beta f_i(y), \quad i = 0, 1, \dots, m, \quad \forall \alpha, \beta \in \mathbb{R}, \quad \forall x, y \in \mathbb{R}^n$$

本课程主要介绍凸优化问题，凸优化问题要求目标函数和所有不等式约束均为凸函数，即：

$$f_i(\alpha x + \beta y) \leq \alpha f_i(x) + \beta f_i(y), \quad i = 0, 1, \dots, m, \quad \forall \alpha, \beta \in \mathbb{R}, \quad \forall x, y \in \mathbb{R}^n$$

可以将凸优化问题看作线性优化问题的推广，是线性规划问题的“松弛”

一般优化问题的求解往往是困难的，在现实情况下只有少量的优化问题可以被简单的精确求解，例如线性优化以及最小二乘问题，现在也有简便的方法和算法来求解凸优化问题。除此之外的优化问题往往需要在求解中进行某些“妥协”，例如使用启发式算

法来寻找局部最优解、使用近似算法进行松弛，将问题分解为凸子问题以求全局最优解等等（但是这种方法的时间复杂度会随着问题规模指数级增长）。

1.2 最小二乘问题和线性规划简介

1.2.1 最小二乘问题

课件中并没有专门提及最小二乘问题，这里只做简单介绍。最小二乘问题是一类没有约束的优化问题，目前有简便的算法可以对大规模的最小二乘问题进行快速且精确的求解。最小二乘问题的目标函数为 $a_i^T x - b_i$ 的平方和，形式为：

$$\text{minimize } f_0(x) = \|Ax - b\|^2 = \sum_{i=1}^m (a_i^T x - b_i)^2$$

这里 A 是一个 $m \times n$ 的矩阵， b 是一个长度为 m 的向量， x 是一个长度为 n 的向量。

最小二乘问题是一类简单的凸优化问题，目标函数 $f_0(x) = \|Ax - b\|^2$ 是一个关于 x 的二次函数，自然是凸的。对 x 求导（求梯度）有：

$$\begin{aligned}\nabla f_0(x) &= 2A^T(Ax - b) \\ \text{令梯度为零 } 0 &= A^T(Ax - b) \\ \text{即 } A^T Ax &= A^T b\end{aligned}$$

由于目标函数的凸性，其导函数单调，极值点就是最值点，故满足如上方程时目标函数值最小。当且仅当 A 满秩时，该线性方程组有唯一解 $x = (A^T A)^{-1} A^T b$

最小二乘问题有许多实际应用，例如线性拟合等等、控制优化等等。常常有加权形式的最小二乘问题（用于平衡在线性拟合中不同变量方差不齐的问题）：

$$\sum_{i=1}^n w_i (a_i^T x_i - y_i)^2 \rightarrow \min$$

或者带有 L2 正则化的最小二乘问题（用于防止解向量绝对值过大，例如用于线性回归模型，让解向量更“合理”）：

$$\sum_{i=1}^n (a_i^T x_i - y_i)^2 + \rho \|x\|^2 \rightarrow \min$$

以上两种最小二乘问题将在第六章和第七章中给出更加详细的解释。

1.2.2 线性规划

课件中同样没有专门提及，仅作简单介绍。线性规划问题的目标函数和所有不等式约束均为线性的，形式为：

$$\begin{aligned} \min f(x) &= c^T x \\ \text{subject to } Ax &\leq b \\ x &\geq 0 \end{aligned}$$

同最小二乘问题一样，线性规划问题也没有所谓“解析解”，也就是不能用一个方程给出优化问题的最优解，但是有简单的步骤可以用于求解线性规划问题。例如，对于简单的（只有两个决策变量）线性规划问题，可以使用图解法；对于更复杂的线性规划问题可以采用单纯形法甚至内点法来求解。

1.3 凸优化简介

对于凸优化问题，我们给出同前文等价的定义：

$$\begin{aligned} \min_{x \in X} \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & g_i(x) = 0, \quad i = 1, \dots, p \\ & \forall i, \quad f_i(\theta x + (1 - \theta)x) \leq \theta f_i(x) + (1 - \theta)f_i(x) \end{aligned}$$

也就是 f_i 具有非负的曲率。

事实上求解凸的优化问题是简单的，有诸如内点法、一阶方法（first-order methods）等方法，可以迅速的使用简单的编程工具（使用凸优化领域的特定语言 DSLs，以及一种编程语言下的工具例如（CVXPY）来解决。

1.4 非线性（且非凸的）优化简介

除了凸优化以外的优化问题，往往是棘手的。主要有启发式算法求局部解（这种解法往往对初值条件和超参数有要求），松弛求解以及转换为凸子问题求全局最优解等解法，这里不详细介绍。

1.5 教材大纲

本书主要包含三个部分：理论基础、应用和算法

第一部分中主要介绍凸分析和凸优化的基本定义。其中第二章和第三章主要介绍凸集和凸函数，并且介绍一些保持凸性的计算方式，第四章给出一部分凸优化问题的子类，给出一部分问题转化为凸优化问题的方法，包含二阶圆锥规划和半正定规划等，第五章介绍一些重要的凸优化问题的性质，例如拉格朗日对偶性、KKT 条件等，并且给出凸优化问题的局部以及全局的灵敏度分析。

第二部分的主要内容是介绍如何在实践中应用凸优化，给出了在概率统计、计算几何以及数据拟合中的各种应用。

第三部分主要给出解决凸优化问题的各种数值计算方法，重点介绍了牛顿法和内点法，然后给出其它少数几种算法。

1.6 符号表示

详见课本 p697 不详细介绍了。

Part II

理论基础

Chapter 2

凸集


2.1 仿射集和凸集

2.1.1 直线集

对于 $\mathbb{R}^n$ 中的两点 x_1 和 x_2 , 我们可以定义它们构成的直线集为:

$$y = \mathcal{L}(x_1, x_2) = \{\theta x_1 + (1 - \theta)x_2 \mid \theta \in \mathbb{R}\}$$

也就是所有的 $\theta \in \mathbb{R}$ 对应的点的集合, 也可以认为是 x_1 和 x_2 所在直线上所有点的集合。



如果令上述定义式中的 $\theta \in [0, 1]$, 则称集合为 x_0 到 x_1 之间的线段。

2.1.2 仿射集

集合 $C \subseteq \mathbb{R}^n$ 是仿射集当且仅当

$$\forall x_1, x_2 \in C, \exists \theta \in \mathbb{R}, x_0 = \theta x_1 + (1 - \theta)x_2 \in C$$

这意味着仿射集包含其中任意向量的任意线性组合。在这里线性组合可以扩展的定义为 $y = \sum_{i=1}^n a_i x_i$, 其中 $\sum_{i=1}^n a_i = 1$ 。

例如, 线性方程组的解空间是一个仿射集。考虑方程组 $Ax = b$, 其中有 $A \in \mathbb{R}^{m \times n}$ 以及 $b \in \mathbb{R}^m$, 则集合 $C = \{x \in \mathbb{R}^n | Ax = b\}$ 是仿射集, 因为对于任意的 $x_1, x_2 \in C$, 我们有 $Ax_1 = b$ 和 $Ax_2 = b$, 则对于任意的 $\theta \in \mathbb{R}$, 有:

$$A(\theta x_1 + (1 - \theta)x_2) = \theta Ax_1 + (1 - \theta)Ax_2 = b$$

一个仿射集的平移仍然是仿射集。例如对一个仿射集 C , 定义其 x_0 平移集合为

$$V = C + x_0 = \{x - x_0 | x \in C\}$$

那么 V 仍是仿射集, 因为对于任意的 $x_1, x_2 \in V$, 存在 $x'_1, x'_2 \in C$ 使得 $x_1 = x'_1 + x_0$ 和 $x_2 = x'_2 + x_0$, 则有:

$$\theta x_1 + (1 - \theta)x_2 = \theta(x'_1 + x_0) + (1 - \theta)(x'_2 + x_0) = \theta x'_1 + (1 - \theta)x'_2 + x_0$$

因此 $\theta x_1 + (1 - \theta)x_2 \in V$

包含集合 C 中所有仿射组合的最小集合称为 C 的仿射包 (affine hull), 记为 $\text{aff}(C)$ 。仿射包是一个仿射集, 包含集合 C 中的所有点。

集合 C 的仿射维度定义为集合仿射包的维度。例如单位圆周 $C = \{x \in \mathbb{R}^2 | \|x\| = 1\}$ 的仿射包为 $\mathbb{R}^2$ (显然圆周上任意不共线的三点的线性组合可以铺满整个二维平面), 于是单位圆周的仿射维度为 2。

定义集合 C 的内点集为:

$$\text{relint}(C) = \{x \in C | B(x, r) \cap \text{aff}(C) \subseteq C, \exists r > 0\}$$

这里 $B(x, r) = \{y | \|y - x\| \leq r\}$, $\|\cdot\|$ 是任意范数 (也就是距离度量)。

2.1.3 凸集

集合 $C \subseteq \mathbb{R}^n$ 是凸集当且仅当对于任意的 $x_1, x_2 \in C$, 以及任意的 $\theta \in [0, 1]$, 都有:

$$\theta x_1 + (1 - \theta)x_2 \in C, \quad \theta \in [0, 1]$$


换句话说, 就是集合中的任意点都能直接“看”到其它点。显然, 一般仿射集都是凸集 (因为其中包含了任意两点之间的线段)。

定义一般集合 C 的凸包为:

$$\text{conv}(C) = \{x \in \mathbb{R}^n | x = \sum_{i=1}^m \theta_i x_i, \quad \sum_{i=1}^m \theta_i = 1, \quad \theta_i \geq 0, \quad x_i \in C\}$$

凸包是包含集合 C 的最小凸集。凸包的几何意义是将集合 C 中的所有点连接起来, 形成一个凸 (至少不凹) 形状。

以上定义 (凸集 & 凸包) 的有限和等式也可以推广为无限和等式甚至是黎曼积分的形式, 只需要保证所有系数项求和结果为 1 即可。



2.1.4 锥体


集合 C 是锥体（或称为非负齐次的）当且仅当对于任意的 $x \in C$ 和任意的 $\theta \geq 0$ ，都有 $\theta x \in C$ 。也就是锥体中的任意点都可以被任意放大或缩小（只要缩小不为负数）。

集合 C 是凸锥体当且仅当它是锥体并且是凸集。也就是对于任意的 $x_1, x_2 \in C$ 以及任意的 $\theta_1, \theta_2 \geq 0$ ，都有：

$$\theta_1 x_1 + \theta_2 x_2 \in C$$

集合 C 的锥包定义为其中所有元素的“锥”组合，即

$$\left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in C, \theta_i \geq 0 \right\}$$



2.2 重要示例

2.2.1 简单凸集示例

- 空集 $\emptyset$ 、单点集 $\{x_0\}$ 、实空间 $\mathbb{R}^n$
- 任何直线都是仿射集（也就是凸集），如果线段经过原点，则其还是凸锥
- 线段是凸集，但是不是仿射集
- 射线是凸集，如果其端点为原点则其还是凸锥
- 任意子空间都是仿射的，并且是凸锥

2.2.2 超平面和半空间

超平面是一个 $n - 1$ 维的仿射集，可以用一个线性方程来定义：

$$\{x \in \mathbb{R}^n | a^T x = b\}$$

其中 $a \in \mathbb{R}^n$, $b \in \mathbb{R}$ 。以上定义式可以移项获得另一种定义式：

$$\{x \in \mathbb{R}^n | a^T (x - x_0) = 0\}$$

其中 x_0 是超平面上任意一点， a 是超平面的法向量（也就是垂直于超平面上所有向量的向量）。该定义式标明超平面由过 x_0 点的所有垂直于 a 的向量构成。

超平面将空间分为两部分，分别称为半空间。半空间是一个 n 维的凸集，可以给出一个（闭的）半空间的定义：

$$\{x \in \mathbb{R}^n | a^T x \leq b\}$$

参考超平面的另一定义式，可以给出半空间的另一种定义式：

$$\{x \in \mathbb{R}^n | a^T (x - x_0) \leq 0\}$$

这个定义式代表的半空间是由所有与超平面法向量 a 夹角大于 90° 的向量所组成的集合，也就是在超平面的“背面”上。

显然超平面是一个仿射集，并且是一个**凸集**，其维度为 $n - 1$ 。半空间也是一个凸集，其维度为 n 。

2.2.3 欧式球和椭球

定义欧氏空间中的范数 $\|\cdot\|$ ： $\|x\| = \sqrt{x^T x}$ 。则在 $\mathbb{R}^n$ 中欧式度量下的球体定义为

$$B(x_c, r) = \{x | \|x - x_c\| \leq r\} = \{x | (x - x_c)^T (x - x_c) \leq r^2\}$$

欧式球也有等价表述：

$$B(x_c, r) = \{x_c + ru | \|u\| \leq 1, u \in \mathbb{R}^n\}$$

欧式球是**凸集**，因为对于任意的 $x_1, x_2 \in B(x_c, r)$ 以及任意的 $\theta \in [0, 1]$ ，都有：

$$\begin{aligned} \|(\theta x_1 + (1 - \theta)x_2) - x_c\| &= \|\theta(x_1 - x_c) + (1 - \theta)(x_2 - x_c)\| \\ &\leq \theta\|x_1 - x_c\| + (1 - \theta)\|x_2 - x_c\| \\ &\leq \theta r + (1 - \theta)r = r \end{aligned}$$

从欧式球可以推广出椭球的概念。椭球是一个 n 维的**凸集**，可以用一个二次型来定义：

$$E(x_c, A) = \{x \in \mathbb{R}^n | (x - x_c)^T A (x - x_c) \leq 1\}$$

其中 A 是一个对称正定矩阵, x_c 是椭球的中心。(正定矩阵的定义是: 对于任意的 $x \in \mathbb{R}^n$, 都有 $x^T A x > 0$, 并且 A 的特征值均为正数, 对称即 $P = P^T$) 也可以写为

$$\mathcal{E} = \{x_c + Au \mid \|u\| \leq 1\}$$

其中 A 是一个非奇异的方阵。

2.2.4 范数球和范数锥

对于 $\mathbb{R}^n$ 中的任意范数 $\|\cdot\|$, 可以定义其范数球为:

$$B(x_c, r) = \{x \in \mathbb{R}^n \mid \|x - x_c\| \leq r\}$$

范数锥为

$$C = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} \mid \|x\| \leq t\} \subseteq \mathbb{R}^{n+1}$$

显然以上二者都是凸集。

那么就有人要问了, 老师老师, 为什么这个锥它要多一个维度呢? 其实原教材没有专门标注 $(x, t) \in \mathbb{R}^n \times \mathbb{R}$, 这里我写出来就是表达范数锥比原空间多了一个“高度”维度, 分别在每个高度上的所有满足 $\|x\| \leq t$ 的点构成整个锥体, 可以想象锥体是不同高度的“层”拼接所得。例如二维向量的锥体就应该是一个三维图像。

特别的, 定义欧式范数下的锥体, 二阶锥体 (Second-Order Cone, SOC) 为:

$$\mathcal{Q} = \{(x, t) \in \mathbb{R}^{n+1} \mid (\sum_{i=1}^n x_i^2)^{\frac{1}{2}} \leq t\}$$

它被叫做二阶锥是因为它是由二次式定义而成的。

2.2.5 多面体

多面体可以定义为

$$\mathcal{P} = \{x \mid a_i^T x \leq b_i, i = 1, 2, \dots, m \text{ 且 } c_j^T x = d_j, j = 1, 2, \dots, p\}$$

这个定义式标明多面体定义为 m 个半空间以及 p 个超平面的交集。直观上可以感受到, 由若干个超平面围成的多面体是一个凸集。

定义式中半空间对应的超平面可以视作二维图形的“边”或者三维图形的“面”; 其中的超平面 (也就是等式条件) 可以视作二维图形中的“截线”或者三维图形的“截面”。显然, 线性无关的等式条件越多, 最后得出的多面体的维度就越低。

例如在二维空间中, 两个线性无关的等式条件 (超平面) 确定的多面体就只有一个点, 三维空间中两个超平面加上一个半空间确定的多面体是一个线段或者一条射线。

单纯形是一类特殊的多面体, 由 $k+1$ 个仿射无关的点 (也就是 k 个向量 $v_1 - v_0, \dots, v_k - v_0$ 之间线性无关) 定义。单纯形 C 的定义为:

$$C = \text{conv}\{v_0, v_1, \dots, v_k\}$$

2.2.6 半正定锥

我们使用 $\mathbb{S}^n$ 来表示所有 $n \times n$ 的对称矩阵的集合（这是一个 $n(n+1)/2$ 维的向量空间），即

$$\mathbb{S}^n = \{X \in \mathbb{R}^{n \times n} | X = X^T\}$$

定义半正定矩阵（对于任意的 $x \in \mathbb{R}^n$ ，都有 $x^T X x \geq 0$ ）

$$\mathbb{S}_+^n = \{X \in \mathbb{S}^n | X \succeq 0\}$$

定义正定矩阵（对于任意的 $x \in \mathbb{R}^n$ ，都有 $x^T X x > 0$ ）

$$\mathbb{S}_{++}^n = \{X \in \mathbb{S}^n | X \succ 0\}$$

以上定义式中， $\succeq$ 和 $\succ$ 分别表示矩阵中的每个元素大于等于/大于 0。这个符号表示偏序关系，具体定义将在后面“广义不等式”节中给出。

2.3 保凸变换

怎么判断一个集合是凸的？主要有三种方法

1. 使用定义判断，即 C 满足 $\forall x, y \in C, \alpha \in [0, 1], \alpha x + (1 - \alpha)y \in C$
2. 使用凸函数判断 (?)
3. 证明 C 是由一个简单凸集（例如多面体，半空间，范数球等）通过保凸变换构成的。
 - 交集运算
 - 仿射映射
 - 透视映射
 - 线性分式映射（形式上是两个仿射函数的比值）

比较之下第二和第三种方法会更加常用，第二种方法会在下一章中给出，本章介绍第三种方法。

2.3.1 交集

凸集族在任意交运算下保持凸性（即使是无限的可列交乃至不可数交）。最简单的凸集交的例子是不同多面体的交，事实上多面体本身就是用多个半空间以及超平面的交定义的，在此基础上再加上更多半空间以及超平面的限制，最后得到的仍然是一个多面体（最严格的情况下得到 $\emptyset$ ），仍然是凸集。

这一性质可以简单的理解，凸集中的所有元素都应当满足凸集成立的条件 $\forall x_1, x_2 \in C, \theta x_1 + (1 - \theta)x_2 \in C, \theta \in [0, 1]$ ，不同的凸集中的点都满足这个条件，许多凸集的交集的点会满足每个凸集的限制，那么自然在这个交集的点会满足凸集的要求。

相应的，并运算却不一定能保证凸性，例如说两个不同的单点集的并，是一个仅仅含有两个点的集合，显然不是凸集。这是因为并集中的点可能不满足其中某个集合的凸集要求，进而不满足整个集合的凸集要求。

2.3.2 仿射变换

凸集在仿射变换下仍然是凸集。仿射变换

$$f: \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad f(x) = Ax + b$$

其中 $A \in \mathbb{R}^{m \times n}$ 和 $b \in \mathbb{R}^m$ 。此时凸集 S 的象 $f(S) = \{f(x)|x \in S\}$ 仍然是凸集，类似的，凸集 S 在仿射变换下的逆象 $f^{-1}(S) = \{x|f(x) \in S\}$ 仍然是凸集。

几个仿射变换简单的例子，经过以下变换后的结果集仍然为凸集。

- 缩放变换 ($\alpha S = \{\alpha x|x \in S\}$)
- 平移变换 ($S + a = \{x + a|x \in S\}$)
- 投影变换 ($T = \{x_1 \in \mathbb{R}^m|(x_1, x_2) \in S \subseteq \mathbb{R}^{m \times n}, \text{其中 } x_2 \in \mathbb{R}^n\}$)
- 加和变换 ($S_1 + S_2 = \{x_1 + x_2|x_1 \in S_1, x_2 \in S_2\}$)
- 笛卡尔积 ($S_1 \times S_2 = \{(x_1, x_2)|x_1 \in S_1, x_2 \in S_2\}$)
- 部分和 ($S = \{(x_1 + x_2, y)|(x_1, y) \in S_1, (x_2, y) \in S_2\}$)

接下来给出一些“更有挑战性”的例子。

1. 多面体：对于多面体 $\mathcal{P}\{x|Ax \preceq b, Cx = d\} \in \mathbb{R}^{m \times p}$ ， $\mathcal{P}$ 可以表示为实空间正部 $\mathbb{R}_+^m \times 0^p$ 在仿射函数 $f(x) = (b - Ax, d - Cx)$ 下的逆象。这里 m 是多面体不等式约束的数量， p 是多面体等式约束的个数。如果是这 p 个等式都是线性无关的，那么 $\mathcal{P}$ 就是一个 m 维的图形。

$f(x)$ 是仿射函数，因为它可以写成 $f(x) = (b, d) - (Ax, Cx)$ ， b, d 分别是 m, p 维的向量， (b, d) 就是一个 $m + p$ 维的向量， $f(x)$ 就是线性变换 $-(Ax, Cx)$ 加上常数 (b, d) 的形式，是仿射变换。

对于逆象集 $f^{-1}(\mathbb{R}_+^m \times \{0\}^p) = \{x \in \mathbb{R}^n|f(x) \in \mathbb{R}_+^m \times \{0\}^p\}$ ，这意味着 $f(x) = (b - Ax, d - Cx) \in \mathbb{R}_+^m \times \{0\}^p$ ，也就是说 $b - Ax \in \mathbb{R}_+^m$ ， $d - Cx \in \{0\}^p$ ，移项即得 $Ax \leq b$ 和 $Cx = d$ 。由于 $\mathbb{R}_+^m \times \{0\}^p$ 是个凸集，则其在仿射变换下的逆象 $\checkmark$ 也是凸集。

2. LMI（线性矩阵不等式）的解集。LMI 定义为

$$A(x) = x_1 A_1 + x_2 A_2 + \dots + x_n A_n \preceq B$$

其中系数 $A_i \in \mathbb{S}^m$ 。

这里需要注意 LMI 和普通线性不等式的区别，普通线性不等式是标量不等式，其系数是一个 $n \times 1$ 的向量，而 LMI 的系数是一系列对称矩阵。普通线性不等式的解集是一个半空间，而 LMI 的解集是一个凸锥的子集，是所有使得 $A(x)$ 半正定的点的集合，其可能有复杂的曲面边界。

显然 LMI 的解集是一个多面体，是一个凸集。事实上，解集还是半正定锥在仿射变换 $f: \mathbb{R}^n \rightarrow \mathbb{S}^m$, $f(x) = B - A(x)$ 的逆象，也就是要求 $B - A(x) \in \mathbb{S}_+^m$ 。

3. 椭球体 $\mathcal{E} = \{x | (x - x_c)^T P^{-1} (x - x_c) \leq 1\}$ 是单位欧式球 $\{u | \|u\| \leq 1\}$ 在仿射变换 $f(u) = P^{\frac{1}{2}}u + x_c$ 下的像，也是单位球在 $g(x) = P^{-\frac{1}{2}}(x - x_c)$ 下的逆象。

我们发现凡是用一次不等式组构造出的集合都很容易找到一次变换（仿射变换），使得某个集合（往往是恒非负的某些集合）的逆象是所构造的集合。


2.3.3 透视变换

透视变换定义为

$$P: \mathbb{R}^n \times \mathbb{R}_{++} \rightarrow \mathbb{R}^n, \quad P(x, t) = \frac{x}{t} \quad (2.1)$$

透视变换对于不同的 t 会拉出一个“透视体”来，变换后的集合相当于是用超平面 $\{x | (0, \dots, 0, t)^T x = 0\}$ 去截取这个透视体所得到的一个成比例放大或缩小的原集合。凸集经过透视变换后仍然是一个凸集，同样的，凸集经过透视变换的逆变换后仍然是凸集。

例如对于一维点集 $\{x_1, x_2, x_3\}$ ，我们可以用“小孔成像”的原理来理解，画出它的透视体（这里的结果是倒过来的，也就是一个负的透视变换），如下图所示，给出了 t 等于 1.5 时的透视体。



2.3.4 线性分式变换

线性分式变换定义为

$$\frac{P(x)}{Q(x)} = \frac{a}{b} + \frac{c}{d} + \frac{e}{f} + \cdots \quad (2.2)$$

凸集在线性分式变换下的象集或者原象集都是凸集。线性分式变换可以化为透视变换加上仿射变换……

一个小栗子：条件概率函数 $f_{ij} = \frac{p_{ij}}{\sum_{k=1}^n p_{kj}}$ 是线性分式变换。

2.4 广义不等式（偏序）

2.4.1 真锥以及偏序

一个集合 $K \subseteq \mathbb{R}^n$ 如果同时满足以下四个条件，那么它是一个真锥：

- K 是一个凸集
- K 是一个闭集
- K 的内部非空
- K 是“尖的”，意味着其中不包含任何直线。

常见的例子有非负象限 $\mathbb{R}_+^n$ ，半正定矩阵锥 $\mathbb{S}_+^n$ 以及二阶锥（SOC）等等。

通过一个真锥，我们可以唯一的确定一个 $\mathbb{R}^n$ 上的偏序 $\preceq$ 。定义真锥对应的偏序为：

$$x \preceq_K y \Leftrightarrow x \preceq y \vee x = y \quad (2.3)$$

类似的定义严格偏序：

$$x \prec_K y \Leftrightarrow x \preceq_K y \wedge x \neq y \quad (2.4)$$

几个简单的偏序的例子：

1. 向量的分量偏序：真锥 $K = \mathbb{R}_+^n$ ，对 $x = (x_1, \dots, x_n), y = (y_1, \dots, y_n)$ ， $x \preceq_K y \Leftrightarrow (x_1, \dots, x_n) - (y_1, \dots, y_n) \in K \Leftrightarrow x_i \leq y_i$ 。
2. 矩阵偏序：对于正定矩阵锥（是真锥） $\mathbb{S}_+^n$ ，其对应的偏序为 $x \preceq_K y \Leftrightarrow \text{support}(x) \subseteq \text{support}(y)$ ，也就是要求两个矩阵 x 和 y 相减所得的矩阵应当是正定的。
3. 多项式偏序：由非负多项式锥 $K = \{c \in \mathbb{R}^n \mid \sum_{i=1}^n c_i t^{i-1} \geq 0, \forall t \in [0, 1]\}$ ，则两个多项式 $c \preceq d \Leftrightarrow \sum_{i=1}^n c_i t^{i-1} \leq \sum_{i=1}^n d_i t^{i-1}, \forall t \in [0, 1]$

偏序的性质

偏序有很多性质和在 $\mathbb{R}$ 上的 $\leq$ 十分相似，例如在加法下偏序保持不变，也就是说对于任意 x, y, u, v ，有 $x \preceq y \wedge u \preceq v \Rightarrow x + u \preceq y + v$

除此之外，偏序有传递性 ($x \preceq y \wedge y \preceq z \Rightarrow x \preceq z$)，自反性 ($x \preceq x$)，非负数乘不变性 ($\forall \alpha \geq 0, \forall x, y, x \preceq y \Rightarrow \alpha x \preceq \alpha y$)，保极限性 (对 $\{x_i\}$, $x_i \preceq y \Rightarrow \lim x_i \preceq \lim y$) 和反对称性 ($x \preceq y \wedge y \preceq x \Rightarrow x = y$)。

2.4.2 最大最小元

这一部分课件上没有提及，这里简单做介绍。偏序关系和实数上的比较关系有一点不同，实数是有严格顺序的，也就是全序集，任意两个实数都是可以比出大小的，然而一般偏序集却可能没有这种性质，可能存在两个不同的元素但是它们之间无法比较。例如对于一个二元集合 $\{a, b\}$ 的幂集 $\{\emptyset, \{a\}, \{b\}, \{a, b\}\}$ ，我们定义偏序为“包含关系”，那么我们会发现 $\{a\}$ 和 $\{b\}$ 之间无法比较。因此，偏序关系下最大最小元的存在性会比实数集合上稍稍复杂一些。

我们定义 $\prec$ 下的最大元 x 满足 $y \prec x, \forall y \in S$ ，类似的定义最小元 x 满足 $x \prec y, \forall y \in S$ 。由于要和所有元素比较，而偏序关系下可能有些集合之间不可比较，所以最大最小元不一定存在。但是如果最大最小元存在，那么它们分别都是唯一的。(我们可以简单的确定最大最小元在某些情况下一定存在，例如有限全序集中一定存在)

2.5 分离超平面和支撑超平面

2.5.1 超平面分离定理

超平面分离定理：如果两个不相交的凸集都是开集，那么它们之间有一个超平面（并且与二者都不交）or 如果两个不相交的凸集都是闭集并且至少有一个是紧的（任意开覆盖有有限子覆盖，在 $\mathbb{R}^n$ 中意味着有界闭集），那么他们之间有一个超平面（并且与二者都不交）。课本上给出的超平面分离定理是更弱的，大意是对于两个不交的凸集，一定存在超平面分割它们，使得不存在点在超平面的“对侧”。

定理证明大意

对于闭集的情形，设 A, B 为两个闭集，一定可以找到两个集合间的最近点对 $a_0 \in A, b_0 \in B$ 使得 $\|a_0 - b_0\| = d(A, B) > \epsilon > 0$ ，此时由凸集的最佳逼近定理，对于 $\forall x \in A$, $(b_0 - a_0)^T(x - a_0) \leq 0$ ，这也就是说 A 中的 a_0 到所有点的向量 $\overrightarrow{a_0 x}$ 与 $\overrightarrow{b_0 a_0}$ 的方向相反（其余所有点都不如 a_0 离 b_0 近，反应了集合的凸性），对于集合 B 中所有点同理有 $\forall y \in B$, $(a_0 - b_0)^T(x - b_0) \leq 0$ 。我们令超平面的法向量 $c = (b_0 - a_0)$ ，依据之前最佳逼近定理所得的不等式，容易推知 $c^T x \leq c^T a_0, c^T y \geq c^T b_0$ ，于是有 $\sup_{x \in A} c^T x \leq c^T a_0 < c^T b_0 \leq \inf_{y \in B} c^T y$ ，可以取得 $\gamma = \frac{c^T a_0 + c^T b_0}{2}$ 使得 $\sup_{x \in A} c^T x < \gamma < \inf_{y \in B} c^T y$ ，也就是存在超平面 $c^T x = \gamma$ 分离了两个凸集。

2.5.2 支撑超平面

对于一个集合 $C \subseteq \mathbb{R}^n$ ，对于非零向量 a ，如果 $a^T x \leq a^T x_0$ ，其中 x_0 是 C 的某一边界点（这里边界点的定义是 C 的闭包差去 C 的内点集），那么超平面 $\{x | a^T x = a^T x_0\}$ 称为 C 的支撑超平面。

支撑超平面定理

对于任意非空凸集 C ，对于其任意边界点，都有过该点的支撑超平面。事实上，如果 C 的内点集不为空，可以由 C 的内点集和单点集 $\{x_0\}$ 的超平面分离定理立即得到结果（这里的超平面分离定理指的是课本中叙述的条件更宽松的定理）。

2.5.3 集合的支撑函数

这部分只在教材上的例题或练习中出现过，但是仍然十分重要，故这里单开一小节来介绍。

设 $C \subseteq \mathbb{R}^n$ 是一个非空集合，其支撑函数（support function）定义为 $h_C(y) : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ ，其定义为：

$$h_C(y) = \inf\{t : y \in C + t\} \quad (2.5)$$

直观的解释，支撑函数 $h_C(y)$ 表示在方向 y 上，集合 C 能延伸“多远”；换句话说，支撑函数的值就等于支撑超平面在方向 y 上与原点之间的符号有向距离乘上 $\|y\|$ 。

支撑函数有一些不错的性质

- 凸性：不论 C 是否是凸的， h_C 总是关于 y 的凸函数。
- 正齐次性（线性）： $h_C(\alpha y) = \alpha h_C(y), \forall \alpha \geq 0$
- 次可加性：如果 C 是凸集，那么有 $h_C(y+z) \leq h_C(y) + h_C(z)$
- 凸集包含的判断： $C \subseteq D \iff h_D(y) \geq h_C(y)$

2.6 对偶锥和广义不等式

课件上没说，先不学了……吗？

2.6.1 对偶锥

对于任意锥体 K （即使它不是一个凸锥），定义其对偶锥 K^* 为集合 $K^* = \{y | x^T y \geq 0, \forall x \in K\}$ 。 K^* 必定是一个闭且凸的锥。

有一个神奇的性质是 K^{**} 为集合 K 的凸包，也就是 K 的对偶锥的对偶锥是它的凸包。

2.6.2 对偶锥体诱导的偏序

对于真锥 K ，其对偶锥 K^* 也是真锥，也可以诱导一个偏序。这个新的偏序有一条重要的性质：

$$x \preceq_K y \Leftrightarrow \lambda^T x \leq \lambda^T y, \forall \lambda \preceq_{K^*}$$

Chapter 3

凸函数

3.1 基本属性和示例

一个函数是凸函数当且仅当其定义域为凸集且

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y), \quad \forall x, y \in D, \theta \in [0, 1]$$

严格凸函数定义为当 $x \neq y \wedge 0 < \theta < 1$ 时，上述不等式的不等号严格成立。如果函数 $-f$ 是凸的，那么我们就说 f 是一个凹函数，相应的若 $-f$ 是严格凸的，则 f 是严格凹函数。例如仿射函数总会使得上述不等式中等号成立，于是仿射函数既是凸的又是凹的，然而其既不是严格凸函数也不是严格凹函数。¹

3.1.1 凸函数的一种判定方法

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数当且仅当 $g : \mathbb{R} \rightarrow \mathbb{R}$, $g(t) = f(x + tv)$ 在定义域 $\text{dom}g = \{t | x + tv \in \text{dom}f, \forall x \in \text{dom}f, v \in \mathbb{R}^n\}$ 上是凸的。这种判断方法的直观理解就是去判断函数 f 图像的“切片”是否是凸的，如果每个切片都是凸的，那么原函数就是凸的。事实上其中 $v \in \mathbb{R}^n$ 就是一个切片的方向，而 t 就决定了要在这个方向上走多远， x 就是切片的起点

3.1.2 凸函数的延拓

将凸函数的定义域延拓到 $\mathbb{R}$ ，将值域扩展到 $\mathbb{R} \cup \{+\infty\}$ 是一种很方便的延拓方法，具体的操作是令 $f(x) = f(x), \text{ if } x \in \text{dom}f, \text{ else } f(x) = +\infty$

这种操作不会改变函数在原定义域内的凸性，同时使函数在 $\mathbb{R}$ 上有定义，且是凸函数。

¹注：接下来的讨论中，凹函数总是和凸函数有相似的定义/性质（往往只相差一个符号），一般用凸函数的性质进行简单推导就可以得到凹函数的性质，于是不再单独讨论。

3.1.3 凸函数的一阶条件

若函数 f 是一阶可微的，也就是它定义域中每点的梯度都存在时，我们给出函数 f 是凸函数的一阶条件（充要条件，可以很方便的从凸函数的定义上证明）：

$$f(y) \geq f(x) + \nabla f(x)^T(y - x), \forall x, y \in \text{dom} f$$

这意味着 y 处的函数值永远大于以 x 为起始点的一阶泰勒近似的函数值。

一些方便理解的解释

零阶泰勒近似的图像可以认为是在“取值维度”上恒等于 $f(x)$ 的一张超平面，也就是与“取值维度”垂直；一阶泰勒近似的图像可以认为是与 $f(x)$ 图像在 x 处相切的超平面（例如一元函数，取值维度一般就是 y ，那零阶近似就是直线 $y = f(x)$ ，一阶近似就是 $y = f(x) + f'(x)(y - x)$ ，对于更多元的函数，就有以上一阶条件中的表示方法）。

于是一阶条件表达的就是：在任意 y 处的函数取值一定大于函数在 x 处的切超平面在 y 处的取值，也就是说函数图像比函数在任意一点处的切超平面都要“高”（这个切平面是全局的最低估计值），那么此时这个函数就是凸的。

3.1.4 二阶条件

若函数 $f(x)$ 是二阶可微的，也就是其定义域内每点的黑塞矩阵或者二阶导数都存在时，给出 f 是凸函数的二阶条件（同样也是充要条件）：

$$\nabla^2 f(x) \succeq 0$$

这个条件可以通过对一阶条件移项 + 取极限而轻松得到。

如果 $\nabla^2 f(x) \succ 0$ ，则称 $f(x)$ 是严格凸的。

3.1.5 常见的凸函数例子

- 正定/半正定二次型
- 最小二乘的目标函数
- 线性二次函数
- 对数指数和函数（特指函数 $f(x) = \log(\sum_{k=1}^n \exp(x))$ ）
- 几何平均数
- 负熵函数
- 范数

3.1.6 下水平集

函数 $f(x)$ 的 α 下水平集定义为:

$$C_\alpha = \{x \in \text{dom}f | f(x) \leq \alpha\} \quad (3.1)$$

显然, 一个凸函数的任意下水平集肯定是凸集, 而反之则不然, 例如 $f(x) = -e^x$ 并非一个凸函数, 然而它的下水平集都是凸集。下水平集的定义主要在拟凸函数处会用到。

3.1.7 上境图

函数 $f(x)$ 的上境图 (Epigraph) 定义为:

$$\text{epi}f = \{(x, t) | x \in \text{dom}f, f(x) \leq t\} \quad (3.2)$$

也就是 $f(x)$ 的图像中大于其函数值的所有点的集合, 可以直观的理解为 $f(x)$ 的图像上方的区域。

3.1.8 詹森不等式

事实上我们有时把凸函数定义的不等式, 即

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y), \quad \forall x, y \in D, \theta \in [0, 1]$$

通过这条基本定义式, 我们能推出凸函数的很多不等式性质。例如, 当 $\theta = \frac{1}{2}$ 时, 有 $f(\frac{x+y}{2}) \leq \frac{f(x)+f(y)}{2}$; 当 $\theta \geq 0$ 时, 若 $\sum \theta_i = 1$, 则有 $f(\sum \theta_i x_i) \leq \sum \theta_i f(x_i) \quad \forall x_i \in D$; 进一步推广至黎曼积分上, 还能得到凸函数期望相关的不等式 $f(\mathbf{E}(x)) \leq \mathbf{E}(f(x))$ 。

3.2 保凸变换

怎么判断一个函数是凸的? 主要有三种方法

1. 通过定义验证 (可以使用“切片”的方式进行检验)
2. 通过二阶条件来验证 (一般用于处理简单的函数) (提问: 为什么不常用一阶条件来验证呢? 答: 解析式好算)
3. 构造性验证 (证明这个函数可以由数个简单的函数通过保凸变换得到)

保凸变换主要有以下几种

- 非负数乘 (可以通过定义简单证明)
- 凸函数的和, 包括凸函数列的无穷和 (这一性质可以通过定义简单证明)

- 凸函数（族）的积分
- 仿射的复合
- 条件相对复杂的一般复合
- 逐点极值（确界）

3.2.1 线性操作

多个凸函数的正系数线性组合所得的函数仍然是凸的。这个性质可以通过定义中的不等式简单得出。对于一个凸函数的正系数 α 数乘而言，有 $\alpha f(\theta x + (1 - \theta)y) \leq \theta \alpha f(x) + (1 - \theta) \alpha f(y) = \alpha(\theta f(x) + (1 - \theta)f(y))$ ，不等式仍然成立；对于两个或者多个凸函数的和，总有 $\sum f_i(\theta x + (1 - \theta)y) \leq \sum(\theta f_i(x) + (1 - \theta)f_i(y))$ ，于是该性质得证。

3.2.2 凸函数与仿射函数的复合

一个凸函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，将它与一个仿射函数 $g: \mathbb{R}^n \rightarrow \mathbb{R}$ 复合，得到 $g(x) = f(Ax + b)$ ， $b \in \mathbb{R}^n, A \in \mathbb{R}^{n \times m}$ ，此时 $g(x)$ 仍然是一个凸函数，这个性质可以通过复合函数求导以及一阶条件或者二阶条件来验证。

函数与仿射函数的复合，可以从向量空间的角度来理解，无非两种状况：

- 1、仿射函数是一个 n 维向量空间中的线性变换，线性变换相当于在不同方向上分别以不同的比例去“拉扯”函数的图像，不会改变图像上点的相对位置关系，自然不会改变函数图像的凹凸性
- 2、仿射函数导致函数自变量“降维”，可以认为是在第一种情况的前提下再直接删除几个维度，那也不会改变函数图像的凹凸性。


3.2.3 逐点极值 or 确界

凸函数列的逐点的极值或者上确界构成的函数仍然是凸函数。例如有凸函数列 $f_1, f_2, \dots, f_n$ ，那么 $g(x) = \max f_i(x)$ （如果最大值存在）， $\sup f_i(x)$ 是一个凸函数。这条性质也可以简单的用定义式证明，也很容易图形化的理解。

3.2.4 部分最小化

对于一个凸函数 $f(x, y), x \in \mathbb{R}^m, y \in \mathbb{R}^n$ ，在凸集 $C \in \mathbb{R}^n$ 上的部分最小化函数 $g(x) = \inf_{y \in C} f(x, y)$ 是一个凸函数。 $g(x)$ 表示在最优的 y 下， f 的最小可能值，可以类比概率论中的边缘概率或者边缘分布？这个性质同样重要，例如在一些优化问题中（例如鲁棒优化），我们可能会遇到 $\min_x(\min_y f(x, y))$ 这样的问题形式，局部最小的凸性传递就可能让这一目标函数成为凸函数，进而使问题简化。

凸函数族的逐点最大值仍为凸函数



本节以及上一节中都需要注意“最大值”或者“最小值”不是总一定能取到的，有界集的确界总是存在的，所以叙述时要注意极值的存在性。

3.2.5 复合函数

凸函数与标量函数复合

对于函数 $g: \mathbb{R}^n \rightarrow \mathbb{R}$ 和 $h: \mathbb{R} \rightarrow \mathbb{R}$ ，令 $f(x) = h(g(x))$ ，则 f 是凸函数 $\iff h$ 凸函数, h 是不增的。只需要对复合函数进行求导，然后用二阶条件即可验证该性质。

一般复合

对于函数 $g: \mathbb{R}^n \rightarrow \mathbb{R}^k$ 以及 $h: \mathbb{R}^k \rightarrow \mathbb{R}$ ，令 $f(x) = h(g(x)) = h(g_1(x), g_2(x), \dots, g_k(x))$ ， f 是凸函数 $\iff$

$(g_i \text{ 是凸函数} \wedge h \text{ 在定义域上不减}) \vee (g_i \text{ 是凹函数} \wedge h \text{ 在定义域上不增}) \vee g_i \text{ 是仿射函数}$

以上性质可以对复合函数进行求导，然后用二阶条件来验证。

3.2.6 透视函数

若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，则 f 的透视函数 (perspective) 是函数 $g: \mathbb{R}^{n+1} \rightarrow \mathbb{R}$ ，定义为

$$g(x, t) = tf\left(\frac{x}{t}\right). \quad (3.3)$$

其定义域为

$$\text{dom } g = \left\{ (x, t) \mid \frac{x}{t} \in \text{dom } f, t > 0 \right\}.$$

透视操作保持凸性：若 f 是凸函数，则其透视函数 g 也是凸函数。类似地，若 f 是凹函数，则 g 也是凹函数。

与集合的透视类似，透视函数也可以很图形化的去理解。透视函数也是在函数原有的维度上增加了一个“高度”维度，额外的，透视函数还为函数乘上了一个“进大远小”的系数。

3.2.7 构造性凸分析

该方法通过将复杂函数分解为基本组件并应用已知的凸性规则，实现了对函数凸性的系统化验证，是连接理论凸分析与实际优化应用的重要桥梁。

在使用这种方法时，可以构建一个“解析树”，每一个叶子节点都是最简单的变量或者常量，树的枝表示一个操作，内部节点是一个由子节点上的值经过一定操作组成的函数，依据之前的各种规则，从叶子节点一步步往前推导，得出根节点（也就是最终的函数）的凸性判断。这种方法具有充分性，也是许多凸优化建模工具（如 CVX 或 CVXPY）的核心验证机制。

3.3 共轭函数

* 据说是最重要的基础知识

对于函数 f ，其共轭函数定义为

$$f^*(y) = \sup_{x \in \text{dom} f} (y^T x - f(x)) \quad (3.4)$$

共轭函数 f^* 总是凸的（即使 f 不是凸的），这个性质也很好证明。我们可以知道上确界中的函数 $g(y) = y^T x - f(x)$ 是一个凸函数（事实上他就是一个线性函数， $f(x)$ 在这里被视作一个常数），那么由逐点上确界的性质，我们可以知道上确界外的函数也是一个凸函数。

共轭函数可以这样理解：上确界中的函数可以理解为过原点的线性函数 $g(x) = y^T x$ 在 x_0 处取值与函数 f 在 x_0 处的函数值 $f(x_0)$ 的差，也就是二者图像之间（在值域维度上）的垂直距离。也就是说，共轭函数的函数值等于选定一个“斜率” y 时，原函数最低低于“斜率面”多远的距离，换个说法就是一定斜率的“斜率面”能在完全不超过原函数的情况下从原点“上移”多远。在一维的函数中，“斜率面”就是正比例函数；在二维函数中，“斜率面”是一个过原点的超平面。

再来一句话总结：共轭函数不是描述“在点 x 的函数值”，而是描述“以斜率 y 的“斜率面”能如何支撑 f ”

3.4 拟凸函数

如果一个函数的所有下水平集都是凸的，那么这个函数称为拟凸函数。具体描述为：对于下水平集 $S_\alpha = \{x \in \text{dom} f | x \leq \alpha\}$ ， f 是拟凸函数，当且仅当 S_α 是凸的，对于 $\forall \alpha \in \mathbb{R}$ 。

拟凸函数有一些性质

- 修正的詹森不等式：当 f 是一个拟凸函数时 $0 \leq \theta \leq 1 \implies f(\theta x + (1 - \theta)y) \leq \max\{f(x), f(y)\}$

- 一阶条件：具有凸定义域的一阶可微函数 f 是拟凸函数时 $\Leftrightarrow (f(y) \leq f(x) \implies \nabla f(x)^T(y - x) \leq 0)$
- 加和仍然是拟凸函数。

Chapter 4

凸优化问题

4.1 优化问题

4.1.1 基本术语

一般地，我们用以下形式来表达一个优化问题：

$$\begin{aligned} \min & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{aligned} \quad (4.1)$$

以上 (4.1) 式表示要在满足约束条件 $f_i(x) \leq 0$ 和 $h_i(x) = 0$ 的情况下，使得目标函数 $f_0(x)$ 最小。我们称 x 为优化变量，函数 $f_0(x)$ 为目标函数或者代价函数，不等式组 $f_i(x) \leq 0$ 称为不等式约束， $h_i(x) = 0$ 称为等式约束。如果一个优化问题没有约束条件（也就是 $m = p = 0$ ），我们称之为无约束的。

所有在两组约束条件（不等式约束和等式约束）的定义域内的点，称为该优化问题的定义域。满足所有约束条件的点称作可行点，否则为不可行点，所有可行点组成该问题的可行域。

优化问题 (4.1) 的最优值 p^* 的定义为

$$p^* = \inf\{f_0(x) | f_i(x) \leq 0, i = 1, 2, \dots, m, h_i(x) = 0, i = 1, 2, \dots, n\}$$

我们允许 p^* 取到正负无穷大。 $p^* = \infty$ 当且仅当这个问题不可行（也就是可行域为空集），若 $\exists$ 可行的 x_0 s.t. $f_0(x_0) = -\infty$ ，则称优化问题 (4.1) 是无下界的（但是并非不可解）。

（全局）最优化和局部最优化

我们说我们解得了 (4.1) 得最优解，就是我们找到一个可行域内的 x^* ，使得 $f_0(x^*) = p^*$ ，所有这样的 x^* 组成的集合，我们称为最优集 X_{OPT} 。如果一个问题的最优集非空，那么我们就说该问题可解的，并且可以取到最优值。在最优值的基础上，我们可以定义

该问题的 ϵ -次优值。一个可行点 x 是若满足 $f_0(x) \geq p^* + \epsilon$, 则称其为 ϵ -次优值。所有 ϵ -次优值的集合组成 (4.1) 的 ϵ -次优集 (ϵ -suboptimal set)。

定义局部最优值: 当一个 x 满足 $\exists R \geq 0$, 使得 $f_0(x) = \inf\{f_0(z) | f_i(z) \leq 0, i = 1, 2, \dots, m, h_i(z) = 0, i = 1, 2, \dots, p, \|z - x\|_2 \leq R\}$ 时, 则 x 为局部最优值。换句话说, x 是一个定义域限制在 x 附近的优化问题的最优解。

事实上, 凸优化问题的任意局部最优值都是全局最优值, 详细证明见??。

4.1.2 问题转化

本节旨在将一个一般问题 (或者说直接由实际问题已知条件推导出的问题) 转化为优化问题的标准形式, 也就是式 (4.1)。在这里我们引入一个“等效问题”的概念。Boyd 等的教材没有给出等效问题的具体数学定义, 只是简单的指出: 等效问题可以理解为当我们得出一个问题的解时, 我们可以立即轻松得出与之等效的另一个问题的解, 进一步的, 如果两个问题具有相同的最优解集, 那么我们认为他们是等效问题。接下来我们的讨论都是在进行等效问题之间的转化。

为什么我们会需要这样的问题转化? 事实上一个标准形式的问题能够大大方便我们去解它, 包括凸优化求解工具 CVX 和 CVXPY 等的使用, 都是建立在标准问题的基础上的。

最大化问题

如前文所述, 我们的优化问题标准形式是一个最小化问题。遇到最大化问题如:

$$\begin{aligned} \max & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p \end{aligned} \quad (4.2)$$

我们只需要将目标函数取负, 得到一个最小化问题 (即将优化目标改为 $\min -f_0(x)$), 然后求解该最小化问题, 得到对应的解, 该解即为原最大问题的最优解。

变量替换 (一一对应的函数复合)

设有一个一一对应的函数 $\phi: \mathbb{R}^n \rightarrow \mathbb{R}^n$, 定义变量替换后的目标函数和约束函数为

$$\begin{aligned} \tilde{f}_i(z) &= f_i(\phi(z)), \quad i = 0, 1, \dots, m \\ \tilde{h}_i(z) &= h_i(\phi(z)), \quad i = 1, 2, \dots, p \end{aligned}$$

其中 ϕ 是定义域覆盖原问题可行域 D 的一一映射 (即 $\phi(\text{dom } \phi) \supseteq D$)。变换后的问题为:

$$\begin{aligned} \min & \tilde{f}_0(z) \\ \text{s.t.} & \tilde{f}_i(z) \leq 0, i = 1, 2, \dots, m \\ & \tilde{h}_i(z) = 0, i = 1, 2, \dots, p \end{aligned} \quad (4.3)$$

两个问题等价: 若 x^* 解决原问题, 则 $z^* = \phi^{-1}(x^*)$ 解决变换后问题; 反之亦然。变量替换通常用于简化约束结构或目标函数形式。

目标函数和约束函数的变换

设 $\psi_0 : \mathbb{R} \rightarrow \mathbb{R}$ 是单调递增函数, $\psi_1, \dots, \psi_m : \mathbb{R} \rightarrow \mathbb{R}$ 满足 $\psi_i(u) \leq 0$ 当且仅当 $u \leq 0$, $\psi_{m+1}, \dots, \psi_{m+p} : \mathbb{R} \rightarrow \mathbb{R}$ 满足 $\psi_i(u) = 0$ 当且仅当 $u = 0$ 。定义变换后的函数:

$$\begin{aligned}\tilde{f}_i(x) &= \psi_i(f_i(x)), \quad i = 0, 1, \dots, m \\ \tilde{h}_i(x) &= \psi_{m+i}(h_i(x)), \quad i = 1, 2, \dots, p\end{aligned}$$

变换后的优化问题与原问题等价。特别地, 当所有 ψ_i 为线性函数时, 即为简单的缩放变换:

$$\begin{aligned}\min & \alpha_0 f_0(x) \\ \text{s.t.} & \alpha_i f_i(x) \leq 0, i = 1, 2, \dots, m \\ & \beta_i h_i(x) = 0, i = 1, 2, \dots, p\end{aligned} \tag{4.4}$$

其中 $\alpha_i > 0$, $\beta_i \neq 0$ 。这种变换不改变问题的可行域和最优解, 仅缩放目标函数和约束函数。

引入松弛变量

对于不等式约束 $f_i(x) \leq 0$, 可以引入松弛变量 $s_i \geq 0$, 将不等式转换为等式约束:

$$f_i(x) + s_i = 0, \quad s_i \geq 0 \tag{4.5}$$

原标准形式问题:

$$\begin{aligned}\min & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p\end{aligned} \tag{4.6}$$

可转换为:

$$\begin{aligned}\min & f_0(x) \\ \text{s.t.} & f_i(x) + s_i = 0, \quad i = 1, 2, \dots, m \\ & s_i \geq 0, \quad i = 1, 2, \dots, m \\ & h_i(x) = 0, i = 1, 2, \dots, p\end{aligned} \tag{4.7}$$

其中 $s \in \mathbb{R}^m$ 是非负松弛变量。转换后的问题与原问题等价, 但将不等式约束转换为等式约束加非负约束, 有时更便于求解。

图像形式 (Epigraph Form)

将原问题转换为:

$$\begin{aligned}\min & t \\ \text{s.t.} & f_0(x) - t \leq 0 \\ & f_i(x) \leq 0, \quad i = 1, 2, \dots, m \\ & Ax = b\end{aligned} \tag{4.8}$$

其中 (x, t) 是新变量。此问题与原问题等价： (x^*, t^*) 是最优解当且仅当 x^* 是原问题的最优解且 $t^* = f_0(x^*)$ 。图像形式问题的目标函数是线性的，这在某些情况下非常有用，特别是当原目标函数复杂时。

分段线性最小化转换为线性规划

对于分段线性最小化问题：

$$\min \max_{i=1, \dots, m} (a_i^T x + b_i) \quad (4.9)$$

通过引入辅助变量 t ，可以转换为线性规划问题：

$$\begin{aligned} \min & t \\ \text{s.t.} & a_i^T x + b_i \leq t, \quad i = 1, 2, \dots, m \end{aligned} \quad (4.10)$$

这展示了如何将一个看似非线性的优化问题转化为标准线性规划问题。

线性分式规划转换

对于线性分式规划问题：

$$\begin{aligned} \min & \frac{c^T x + d}{e^T x + f} \\ \text{s.t.} & e^T x + f > 0 \\ & Gx \leq h \\ & Ax = b \end{aligned} \quad (4.11)$$

可通过变量替换 $y = x/(e^T x + f)$ 和 $t = 1/(e^T x + f)$ ，转换为线性规划问题：

$$\begin{aligned} \min & c^T y + dt \\ \text{s.t.} & Gy - ht \leq 0 \\ & Ay - bt = 0 \\ & e^T y + ft = 1 \\ & t \geq 0 \end{aligned} \quad (4.12)$$

隐式约束表示

定义扩展值延伸函数：

$$F(x) = \begin{cases} f_0(x), & \text{当 } x \text{ 可行} \\ \infty, & \text{当 } x \text{ 不可行} \end{cases}$$

则原问题可表示为无约束问题： $\min F(x)$ 。此转换保持问题等价性，但只是符号上的技巧，未使问题更容易解决。

分离变量与部分极小化

当约束可分离（每个约束仅依赖 x_1 或 x_2 ）时：

$$\begin{aligned}
 & \min f_0(x_1, x_2) \\
 & \text{s.t. } f_i(x_1) \leq 0, \quad i = 1, 2, \dots, m_1 \\
 & \quad \tilde{f}_i(x_2) \leq 0, \quad i = 1, 2, \dots, m_2 \\
 & \quad h_i(x) = 0, \quad i = 1, 2, \dots, p
 \end{aligned} \tag{4.13}$$

可先对 x_2 极小化，定义：

$$\tilde{f}_0(x_1) = \inf\{f_0(x_1, z) \mid \tilde{f}_i(z) \leq 0, i = 1, 2, \dots, m_2\}$$

得到等价问题：

$$\begin{aligned}
 & \min \tilde{f}_0(x_1) \\
 & \text{s.t. } f_i(x_1) \leq 0, \quad i = 1, 2, \dots, m_1
 \end{aligned} \tag{4.14}$$

若 f_0 关于 x_1, x_2 联合凸，且所有约束凸，则等价问题也是凸的。

向量优化问题的标量化

对于向量优化问题：

$$\begin{aligned}
 & \min_{w.r.t. K} f_0(x) \\
 & \text{s.t. } f_i(x) \leq 0, \quad i = 1, 2, \dots, m \\
 & \quad h_i(x) = 0, \quad i = 1, 2, \dots, p
 \end{aligned} \tag{4.15}$$

其中 $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}^q$ 是向量值函数， K 是适当锥。

可通过标量化转换为标量问题：

$$\begin{aligned}
 & \min \lambda^T f_0(x) \\
 & \text{s.t. } f_i(x) \leq 0, \quad i = 1, 2, \dots, m \\
 & \quad h_i(x) = 0, \quad i = 1, 2, \dots, p
 \end{aligned} \tag{4.16}$$

其中 $\lambda \succ_{K^*} 0$ （在对偶广义不等式中为正）。任何此类标量化问题的解都是 Pareto 最优的。

问题转换是凸优化中的核心技巧，通过这些转换，我们可以将各种实际问题重新表述为可有效求解的标准凸优化问题。在实际应用中，选择合适的转换方法对于问题的求解效率和数值稳定性至关重要。

4.2 凸优化问题

4.2.1 凸优化问题的标准形式

凸优化问题的标准形式定义为：

$$\begin{aligned}
& \text{minimize} && f_0(x) \\
& \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\
& && a_i^T x = b_i, \quad i = 1, \dots, p
\end{aligned} \tag{4.17}$$

其中:

- $x \in \mathbb{R}^n$ 是优化变量
- 目标函数 $f_0: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数
- 不等式约束函数 $f_i: \mathbb{R}^n \rightarrow \mathbb{R}$ ($i = 1, \dots, m$) 是凸函数
- 等式约束是仿射的 (即 $a_i^T x - b_i = 0$)
- 问题的定义域 $D = \bigcap_{i=1}^m \text{dom} f_i$ 非空

4.2.2 凸优化问题的基本性质

可行集的凸性凸优化问题的可行

$$\mathcal{C} = \{x \mid f_i(x) \leq 0, i = 1, \dots, m, a_i^T x = b_i, i = 1, \dots, p\}$$

是凸集。

- 凸函数的下水平集 $\{x \mid f_i(x) \leq 0\}$ 是凸集
- 仿射等式约束定义的集合是凸集
- 凸集的交集仍是凸集

局部最优解即全局最优解

凸优化问题中, 任何局部最优解都是全局最优解。

假设 x^* 是局部最优解但不是全局最优解, 则存在可行点 y 满足 $f_0(y) < f_0(x^*)$ 。考虑连接 x^* 和 y 的线段上的点 $x_\theta = \theta y + (1 - \theta)x^*$, 其中 $\theta \in [0, 1]$ 。由凸性:

$$f_0(x_\theta) \leq \theta f_0(y) + (1 - \theta)f_0(x^*) < f_0(x^*)$$

当 θ 足够小时, x_θ 位于 x^* 的邻域内, 这与 x^* 是局部最优解矛盾。

最优集的凸性

凸优化问题的最优解集合

$$\mathcal{X}_{\text{opt}} = \{x^* \mid x^* \text{ 是最优解}\}$$

是凸集。

设 x^* 和 y^* 都是最优解, 令 $p^* = f_0(x^*) = f_0(y^*)$ 。对任意 $\theta \in [0, 1]$, 点 $z = \theta x^* + (1 - \theta)y^*$ 是可行的 (因为可行集是凸集), 且由凸性:

$$f_0(z) \leq \theta f_0(x^*) + (1 - \theta)f_0(y^*) = p^*$$

因此 $f_0(z) = p^*$, 即 z 也是最优解。

严格凸函数的唯一最优解: 如果目标函数 f_0 是严格凸的, 则凸优化问题最多有一个最优解。

假设存在两个不同的最优解 x^* 和 y^* , 则对任意 $\theta \in (0, 1)$, 点 $z = \theta x^* + (1 - \theta)y^*$ 满足:

$$f_0(z) < \theta f_0(x^*) + (1 - \theta)f_0(y^*) = p^*$$

这与 p^* 是最优值矛盾。

4.2.3 凸优化问题的判定

判断一个优化问题是否为凸优化问题, 关键在于验证:

- 目标函数是否凸
- 不等式约束函数是否凸
- 等式约束是否仿射

重要说明: 有时问题的原始形式不明显是凸的, 但通过重新表述可转换为标准凸形式。

转换的栗子: 考虑问题:

$$\begin{aligned} & \text{minimize} && x_1^2 + x_2^2 \\ & \text{subject to} && \frac{x_1}{1 + x_2^2} \leq 0 \\ & && (x_1 + x_2)^2 = 0 \end{aligned}$$

可行集 $\{x \mid x_1 \leq 0, x_1 + x_2 = 0\}$ 是凸的, 但原始问题不是标准凸优化形式 (因为等式约束非仿射, 不等式约束非凸)。可重新表述为:

$$\begin{aligned} & \text{minimize} && x_1^2 + x_2^2 \\ & \text{subject to} && x_1 \leq 0 \\ & && x_1 + x_2 = 0 \end{aligned}$$

这是标准凸优化形式, 因为 f_0 和 f_1 是凸的, h_1 是仿射的。

4.2.4 拟凸优化问题

拟凸优化问题具有标准形式：

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && a_i^T x = b_i, \quad i = 1, \dots, p \end{aligned}$$

其中 f_0 是拟凸函数, f_i ($i = 1, \dots, m$) 是凸函数, 等式约束是仿射的。

拟凸优化问题中, 局部最优解不一定是最优解。但可以使用二分法求解：

- 假设已知最优值 p^* 位于区间 $[l, u]$
- 在每一步, 取中点 $t = (l + u)/2$, 求解凸可行性问题：

$$\begin{aligned} & \text{find} && x \\ & \text{subject to} && f_0(x) \leq t \\ & && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && a_i^T x = b_i, \quad i = 1, \dots, p \end{aligned}$$

- 如果可行, 则 $p^* \leq t$, 令 $u = t$; 否则 $p^* > t$, 令 $l = t$
- 重复此过程直到区间长度小于给定容差

4.2.5 保持凸性的等效问题转换

这里的转换可以很大程度上参考上一节普通优化问题的转化, 只需要确保转化后的目标函数、约束条件以及定义域等都满足凸优化的要求即可, 以下列出几个稍有难度的转化方式 (例如最大化问题如果仅有目标函数是凹的, 其余条件都满足凸优化问题的要求, 那么只需取反即可将其转换为凸优化问题)

变量替换

设 $\phi: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 是一一映射且覆盖问题域 D , 定义变量替换后的目标函数和约束函数为

$$\begin{aligned} \tilde{f}_i(z) &= f_i(\phi(z)), \quad i = 0, 1, \dots, m \\ \tilde{h}_i(z) &= h_i(\phi(z)), \quad i = 1, 2, \dots, p \end{aligned}$$

若 $\tilde{f}_i$ 是凸函数, 则变换后的问题仍是凸优化问题。变换后的问题与原问题等价: 若 x^* 解决原问题, 则 $z^* = \phi^{-1}(x^*)$ 解决变换后问题; 反之亦然。

目标函数和约束函数的变换

设 $\psi_0: \mathbb{R} \rightarrow \mathbb{R}$ 是单调递增的凸函数, $\psi_1, \dots, \psi_m: \mathbb{R} \rightarrow \mathbb{R}$ 满足 $\psi_i(u) \leq 0$ 当且仅当 $u \leq 0$ 且 ψ_i 非减。定义变换后的函数:

$$\begin{aligned} \tilde{f}_i(x) &= \psi_i(f_i(x)), \quad i = 0, 1, \dots, m \\ \tilde{h}_i(x) &= \psi_{m+i}(h_i(x)), \quad i = 1, 2, \dots, p \end{aligned}$$

若 f_0 是凸的, 则 $\tilde{f}_0$ 是凸的; 若 f_i 是凸的, 则 $\tilde{f}_i$ 是凸的。变换后的凸优化问题与原问题等价。

引松弛变量

对于不等式约束 $f_i(x) \leq 0$, 引入松弛变量 $s_i \geq 0$, 将不等式转换为等式约束:

$$f_i(x) + s_i = 0, \quad s_i \geq 0$$

变换后的凸优化问题与原问题等价。

图像形式 (Epigraph Form)

将原问题转换为:

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && f_0(x) - t \leq 0 \\ & && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && a_i^T x = b_i, \quad i = 1, \dots, p \end{aligned}$$

若 f_0 是凸的, 则图像形式问题仍是凸优化问题。此问题与原问题等价: (x^*, t^*) 是最优解当且仅当 x^* 是原问题的最优解且 $t^* = f_0(x^*)$ 。

部分极小化

若 $f_0(x_1, x_2)$ 关于 x_1, x_2 联合凸, 且所有约束凸, 则通过部分极小化得到的等价问题

$$\begin{aligned} & \text{minimize} && \tilde{f}_0(x_1) = \inf\{f_0(x_1, z) \mid \tilde{f}_i(z) \leq 0, i = 1, \dots, m_2\} \\ & \text{subject to} && \tilde{f}_i(x_1) \leq 0, \quad i = 1, \dots, m_1 \end{aligned}$$

仍是凸优化问题。这表明在凸函数上对部分变量进行极小化仍保持凸性。

4.2.6 抽象凸优化问题

有些作者用”抽象凸优化问题”指代在凸集上最小化凸函数的问题。但本书要求可行集必须由凸不等式和线性等式具体描述。

可以将约束隐含在目标函数中 (通过扩展值延伸函数):

$$F(x) = \begin{cases} f_0(x), & \text{当 } x \text{ 可行} \\ \infty, & \text{当 } x \text{ 不可行} \end{cases}$$

则问题可表示为无约束问题: $\min F(x)$ 。此转换保持问题等价性, 但只是符号上的技巧, 未使问题更容易解决。

凸优化问题的这些性质使其成为一类特别重要的优化问题, 不仅因为许多实际问题可以表示为凸优化问题, 还因为它们具有良好的理论性质且可以高效求解。这些理论基础为后续章节讨论的具体凸优化问题类型 (如线性规划、二次规划等) 奠定了基础。

4.3 线性优化问题

线性优化问题（也称为线性规划，Linear Programming，简称 LP）是凸优化问题中最基本且应用最广泛的一类。本节将详细介绍线性规划的标准形式、几何解释、特殊形式、问题转换方法以及典型应用。

4.3.1 线性规划的标准形式

线性规划问题的标准形式定义为：

$$\begin{aligned} & \text{minimize} && c^T x + d \\ & \text{subject to} && Gx \preceq h \\ & && Ax = b \end{aligned}$$

其中：- $x \in \mathbb{R}^n$ 是优化变量 - $c \in \mathbb{R}^n$ 和 $d \in \mathbb{R}$ 定义了线性目标函数 - $G \in \mathbb{R}^{m \times n}$ 和 $h \in \mathbb{R}^m$ 定义了不等式约束 - $A \in \mathbb{R}^{p \times n}$ 和 $b \in \mathbb{R}^p$ 定义了等式约束

线性规划是凸优化问题的一个特例，因为：1. 目标函数 $c^T x + d$ 是仿射函数，因此也是凸函数 2. 不等式约束函数 $g_i(x) = (Gx)_i - h_i$ 是仿射函数，因此也是凸函数 3. 等式约束是仿射的

线性规划问题的可行集 $\{x \mid Gx \preceq h, Ax = b\}$ 是一个多面体（polyhedron），这是一个凸集。线性规划问题的最优解（如果存在）通常出现在可行集的边界上，特别是多面体的顶点处。

4.3.2 线性规划的几何解释

线性规划问题的几何解释非常直观。考虑目标函数 $c^T x$ ，其等值面是垂直于向量 c 的超平面。最小化 $c^T x$ 相当于在可行集内沿着 $-c$ 方向尽可能远地移动，直到碰到可行集的边界。

在二维或三维空间中，可行集是一个多边形或多面体，目标函数的等值线（或等值面）是一系列平行线（或平行平面）。最优解出现在等值线（或等值面）与可行集首次接触的点上，这个点通常位于可行集的顶点或边界上。

例如，考虑一个简单的二维线性规划问题：

$$\begin{aligned} & \text{minimize} && -x_1 - x_2 \\ & \text{subject to} && x_1 + 2x_2 \leq 4 \\ & && 2x_1 + x_2 \leq 4 \\ & && x_1 \geq 0, x_2 \geq 0 \end{aligned}$$

可行集是一个四边形，目标函数的等值线是斜率为-1的直线。最小化 $-x_1 - x_2$ 等价于最大化 $x_1 + x_2$ ，最优解出现在可行集的顶点 $(4/3, 4/3)$ 处。

4.3.3 线性规划的特殊形式

线性规划问题有两种特别常见的形式：

1. 标准形式线性规划：只有非负约束

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && Ax = b \\ & && x \succeq 0 \end{aligned}$$

其中 $x \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$, 且通常假设 $m \leq n$ 且 A 的行是线性独立的。

2. 不等式形式线性规划：只有不等式约束

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && Ax \preceq b \end{aligned}$$

标准形式线性规划在理论分析和算法设计中特别有用，因为它的结构更简单，且可以应用单纯形法等经典算法。

4.3.4 一般线性规划转换为标准形式

任何线性规划问题都可以转换为标准形式。转换过程包括以下步骤：

1. 处理不等式约束：对于每个不等式约束 $a_i^T x \leq b_i$, 引入松弛变量 $s_i \geq 0$, 将不等式转换为等式：

$$a_i^T x + s_i = b_i, \quad s_i \geq 0$$

例如，约束 $x_1 + 2x_2 \leq 4$ 可以转换为 $x_1 + 2x_2 + s_1 = 4$, 其中 $s_1 \geq 0$ 。

2. 处理自由变量：对于每个自由变量（无约束的变量） x_j , 将其表示为两个非负变量的差：

$$x_j = x_j^+ - x_j^-, \quad x_j^+ \geq 0, \quad x_j^- \geq 0$$

例如，如果 x_1 是自由变量，则替换为 $x_1 = x_1^+ - x_1^-$, 其中 $x_1^+ \geq 0$, $x_1^- \geq 0$ 。

3. 处理大于等于约束：对于每个约束 $a_i^T x \geq b_i$, 乘以-1 转换为小于等于约束：

$$-a_i^T x \leq -b_i$$

4. 处理等式右侧为负：如果等式约束 $a_i^T x = b_i$ 中 $b_i < 0$, 可以乘以-1 使右侧非负。

5. 合并变量：将所有新引入的变量与原变量合并，形成新的变量向量。

例如，考虑一般线性规划问题：

$$\begin{aligned} & \text{minimize} && c^T x + d \\ & \text{subject to} && Gx \preceq h \\ & && Ax = b \end{aligned}$$

转换为标准形式的步骤如下：

首先，引入松弛变量 s 处理不等式约束：

$$\begin{aligned} & \text{minimize} && c^T x + d \\ & \text{subject to} && Gx + s = h \\ & && Ax = b \\ & && s \succeq 0 \end{aligned}$$

然后，将变量 x 表示为两个非负变量的差： $x = x^+ - x^-$ ，其中 $x^+ \succeq 0$ ， $x^- \succeq 0$ ：

$$\begin{aligned} & \text{minimize} && c^T x^+ - c^T x^- + d \\ & \text{subject to} && Gx^+ - Gx^- + s = h \\ & && Ax^+ - Ax^- = b \\ & && x^+ \succeq 0, \quad x^- \succeq 0, \quad s \succeq 0 \end{aligned}$$

现在，问题已经转换为标准形式，变量为 $[x^{+T}, x^{-T}, s^T]^T$ 。

4.3.5 线性规划的应用实例

线性规划在许多领域有广泛应用，下面介绍几个典型例子：

1. **饮食问题 (Diet Problem)**：选择食物的量以满足营养需求并最小化成本。- 设 x_j 表示食物 j 的数量 ($x_j \geq 0$) - c_j 表示食物 j 的单位成本 - A_{ij} 表示食物 j 中营养素 i 的含量 - b_i 表示营养素 i 的最低需求

问题可以表述为：

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && Ax \succeq b \\ & && x \succeq 0 \end{aligned}$$

这是一个不等式形式的线性规划，可以通过引入松弛变量转换为标准形式。

2. **网络流问题**：优化网络中的流量以最小化总成本。- 设 x_j 表示弧 j 上的流量 - c_j 表示单位流量在弧 j 上的成本 - 约束包括流量守恒（每个节点流入等于流出）和容量限制

问题可以表述为：

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && Ax = b \\ & && 0 \preceq x \preceq u \end{aligned}$$

其中 A 是网络的关联矩阵， b 表示源点和汇点的净流量， u 是容量限制。

3. **资源分配问题**：在有限资源下最大化收益。- 设 x_j 表示项目 j 的投入量 - c_j 表示项目 j 的单位收益 - A_{ij} 表示项目 j 消耗资源 i 的数量 - b_i 表示资源 i 的总量

问题可以表述为:

$$\begin{aligned} & \text{minimize} && -c^T x \\ & \text{subject to} && Ax \preceq b \\ & && x \succeq 0 \end{aligned}$$

这里最小化 $-c^T x$ 等价于最大化 $c^T x$ 。

4.3.6 分段线性最小化转换为线性规划

分段线性函数是指由多个线性函数段组成的凸函数。最小化分段线性函数可以转换为线性规划问题。

考虑分段线性最小化问题:

$$\text{minimize} \quad \max_{i=1, \dots, m} (a_i^T x + b_i)$$

通过引入辅助变量 t , 可以将问题转换为线性规划:

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && a_i^T x + b_i \leq t, \quad i = 1, \dots, m \end{aligned}$$

这个转换的原理是: $\max_{i=1, \dots, m} (a_i^T x + b_i) \leq t$ 当且仅当对所有 i , $a_i^T x + b_i \leq t$ 。因此, 最小化 t 等价于最小化分段线性函数。

例如, 最小化 $|x_1| + |x_2|$ 可以转换为:

$$\begin{aligned} & \text{minimize} && t_1 + t_2 \\ & \text{subject to} && -t_1 \leq x_1 \leq t_1 \\ & && -t_2 \leq x_2 \leq t_2 \end{aligned}$$

这里 t_1 和 t_2 分别是 $|x_1|$ 和 $|x_2|$ 的上界。

4.3.7 线性分式规划

线性分式规划是目标函数为线性分式函数的优化问题:

$$\begin{aligned} & \text{minimize} && \frac{c^T x + d}{e^T x + f} \\ & \text{subject to} && e^T x + f > 0 \\ & && Gx \preceq h \\ & && Ax = b \end{aligned}$$

通过变量替换 $y = x/(e^T x + f)$ 和 $t = 1/(e^T x + f)$, 可以将线性分式规划转换为线性规划:

$$\begin{aligned} & \text{minimize} && c^T y + dt \\ & \text{subject to} && Gy - ht \preceq 0 \\ & && Ay - bt = 0 \\ & && e^T y + ft = 1 \\ & && t \geq 0 \end{aligned}$$

如果 (y^*, t^*) 是转换后问题的最优解, 那么 $x^* = y^*/t^*$ 是原问题的最优解。

例如, 考虑线性分式规划问题:

$$\begin{aligned} & \text{minimize} && \frac{x_1 + 2}{x_1 + x_2 + 1} \\ & \text{subject to} && x_1 + x_2 + 1 > 0 \\ & && x_1 \geq 0, x_2 \geq 0 \\ & && x_1 + x_2 \leq 1 \end{aligned}$$

通过变量替换 $y_1 = x_1/t$, $y_2 = x_2/t$, $t = 1/(x_1 + x_2 + 1)$, 转换为:

$$\begin{aligned} & \text{minimize} && y_1 + 2t \\ & \text{subject to} && y_1 + y_2 + t = 1 \\ & && y_1 \geq 0, y_2 \geq 0 \\ & && y_1 + y_2 \leq t \\ & && t \geq 0 \end{aligned}$$

4.3.8 线性规划的求解方法和特点

线性规划问题有多种求解方法, 包括:

1. **单纯形法**: 从一个顶点开始, 沿着可行集的边移动到相邻的顶点, 直到找到最优解。虽然在最坏情况下可能需要指数时间, 但在实践中通常非常高效。

2. **内点法**: 从可行集内部开始, 沿着特定路径向最优解移动。内点法具有多项式时间复杂度, 在大规模问题上通常比单纯形法更有效。

线性规划问题具有以下特点:

- 如果可行集非空且有界, 则最优解一定存在
- 如果可行集非空但无界, 最优值可能为 $-\infty$
- 最优解 (如果存在) 通常出现在可行集的顶点上
- 如果存在多个最优解, 则最优解集合是一个多面体

在实际应用中, 线性规划问题通常通过专门的软件包 (如 CPLEX、Gurobi 等) 求解。这些软件包实现了高效的算法, 并提供了用户友好的接口。

4.3.9 线性规划与其他优化问题的关系

线性规划与其他优化问题有密切关系：

1. **二次规划**：如果目标函数是二次凸函数，约束是线性的，则得到二次规划问题，这是线性规划的推广。

2. **半定规划**：如果约束是线性矩阵不等式，则得到半定规划问题，这也是线性规划的推广。

3. **整数线性规划**：如果变量需要取整数值，则得到整数线性规划问题，这是一个 NP 难问题，但可以通过线性规划松弛来近似求解。

线性规划作为最简单的凸优化问题，为理解和求解更复杂的优化问题提供了基础。许多非线性优化问题可以通过线性化或近似转换为线性规划问题，从而利用线性规划的高效算法求解。

总之，线性规划是凸优化理论和应用的核心内容之一。通过理解线性规划的标准形式、几何解释、转换方法 and 应用实例，我们可以更好地掌握凸优化的基本原理，并将其应用于各种实际问题中。

4.4 几何优化问题

几何优化问题（Geometric Programming，简称 GP）是一类特殊的优化问题，其特点是在原始形式下不是凸的，但可以通过变量替换和函数变换转化为凸优化问题。几何规划在工程设计、资源分配、电路设计等领域有广泛应用。

4.4.1 单项式与正项式

几何规划的基础是单项式（monomial）和正项式（posynomial）的概念。

单项式：函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，定义域为 $\mathbb{R}_{++}^n$ （正实数空间），形式为：

$$f(x) = cx_1^{a_1} x_2^{a_2} \cdots x_n^{a_n}$$

其中 $c > 0$ 且 $a_i \in \mathbb{R}$ 。单项式具有以下性质：- 单项式是正函数（值域为正实数）- 两个单项式的乘积仍是单项式 - 单项式与正标量的乘积仍是单项式 - 单项式的幂（指数为实数）仍是单项式

正项式：正项式是单项式的和，形式为：

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} x_2^{a_{2k}} \cdots x_n^{a_{nk}}$$

其中 $c_k > 0$ 。正项式具有以下性质：- 正项式是正函数 - 两个正项式的和仍是正项式 - 两个正项式的乘积仍是正项式 - 正项式与正标量的乘积仍是正项式 - 正项式的幂（指数为正实数）仍是正项式

注意：两个正项式的差不一定是正项式，正项式的倒数也不一定是正项式。

4.4.2 几何规划的标准形式

几何规划的标准形式定义为：

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 1, \quad i = 1, \dots, m \\ & && g_i(x) = 1, \quad i = 1, \dots, p \end{aligned}$$

其中：- $x \in \mathbb{R}_{++}^n$ 是优化变量（所有分量为正）- $f_0, f_1, \dots, f_m$ 是正项式 - $g_1, \dots, g_p$ 是单项式

标准几何规划问题在原始形式下不是凸优化问题，因为：1. 目标函数和约束函数不是凸函数 2. 可行集不是凸集

然而，通过适当的变量替换和函数变换，可以将几何规划问题转化为凸优化问题。

4.4.3 几何规划的凸形式转换

将几何规划转换为凸优化问题的关键步骤是：

1. **变量替换**：令 $y_i = \log x_i$ ，即 $x_i = e^{y_i}$ ，其中 $y_i \in \mathbb{R}$ 。这一替换将变量从正实数空间 $\mathbb{R}_{++}^n$ 映射到整个实数空间 $\mathbb{R}^n$ 。

2. **函数变换**：考虑一个单项式 $f(x) = cx_1^{a_1} \cdots x_n^{a_n}$ ，经过变量替换后：

$$\tilde{f}(y) = f(e^y) = ce^{a_1 y_1 + \cdots + a_n y_n} = e^{\log c + a^T y}$$

取对数后得到：

$$\log \tilde{f}(y) = a^T y + b$$

其中 $b = \log c$ 。这是一个仿射函数，因此是凸函数。

3. 对于正项式 $f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} \cdots x_n^{a_{nk}}$ ，经过变量替换和对数变换后：

$$\log \tilde{f}(y) = \log \left(\sum_{k=1}^K e^{a_k^T y + b_k} \right)$$

其中 $a_k = (a_{1k}, \dots, a_{nk})^T$ ， $b_k = \log c_k$ 。这是一个凸函数，因为：- $e^{a_k^T y + b_k}$ 是凸函数（指数仿射函数）- 凸函数的和是凸函数 - $\log$ 是单调递增的凸函数，且其定义域为正实数 - $\log(\text{凸函数})$ 在适当条件下是凸函数

通过上述变换，几何规划问题可以转换为凸优化问题：

$$\begin{aligned} & \text{minimize} && \log \left(\sum_{k=1}^{K_0} e^{a_{0k}^T y + b_{0k}} \right) \\ & \text{subject to} && \log \left(\sum_{k=1}^{K_i} e^{a_{ik}^T y + b_{ik}} \right) \leq 0, \quad i = 1, \dots, m \\ & && c_i^T y + d_i = 0, \quad i = 1, \dots, p \end{aligned}$$

其中：- $a_{ik} \in \mathbb{R}^n$ 和 $b_{ik} \in \mathbb{R}$ 由原始正项式的系数和指数确定 - $c_i \in \mathbb{R}^n$ 和 $d_i \in \mathbb{R}$ 由原始单项式约束确定

转换后的优化问题目标函数和不等式约束函数都是凸函数，等式约束是仿射的，因此是一个标准的凸优化问题。

4.4.4 几何规划的应用实例

几何规划在许多领域有广泛应用，下面介绍几个典型例子：

1. **电路设计**：在集成电路设计中，需要优化晶体管尺寸以最小化功耗或面积，同时满足性能约束。- 设 x_j 表示晶体管 j 的尺寸（宽度）- 功耗通常可以表示为正项式函数 - 延迟约束通常可以表示为正项式不等式 - 面积约束可以表示为单项式等式

例如，最小化功耗问题：

$$\begin{aligned} & \text{minimize} && \text{功耗}(x) \\ & \text{subject to} && \text{延迟}(x) \leq 1 \\ & && \text{面积}(x) = 1 \\ & && x \succ 0 \end{aligned}$$

其中功耗和延迟是正项式，面积是单项式。

2. **机械设计**：优化机械结构的尺寸以最小化重量或成本。- 考虑一个简单的梁设计问题，需要确定梁的宽度 w 和高度 h - 重量与 wh 成正比（单项式）- 弯曲应力与 $M/(wh^2)$ 成正比，其中 M 是弯矩 - 挠度与 $ML^3/(wh^3)$ 成正比，其中 L 是梁长

问题可以表述为：

$$\begin{aligned} & \text{minimize} && wh \\ & \text{subject to} && \frac{M}{wh^2} \leq \sigma_{\max} \\ & && \frac{ML^3}{wh^3} \leq \delta_{\max} \\ & && w, h > 0 \end{aligned}$$

通过除以右侧常数，可以转换为几何规划标准形式。

3. **无线通信中的功率控制**：在无线网络中优化发射功率以最小化总功耗，同时满足信干噪比 (SINR) 要求。- 设 x_j 表示用户 j 的发射功率 - 信干噪比可以表示为正项式比值 - 通过适当变换，SINR 约束可以表示为正项式不等式

问题可以表述为：

$$\begin{aligned} & \text{minimize} && \sum_{j=1}^n x_j \\ & \text{subject to} && \frac{G_{jj}x_j}{\sum_{k \neq j} G_{jk}x_k + \sigma_j} \geq \gamma_j, \quad j = 1, \dots, n \\ & && x_j > 0, \quad j = 1, \dots, n \end{aligned}$$

其中 G_{jk} 是信道增益, σ_j 是噪声功率, γ_j 是 SINR 要求。通过重新排列不等式, 可以转换为几何规划标准形式。

4. **热力学系统设计**: 优化热交换器的尺寸和操作条件。- 传热面积、流速、温度等变量 - 能量平衡方程通常可以表示为单项式等式 - 成本函数通常可以表示为正项式

4.4.5 广义几何规划

广义几何规划是标准几何规划的扩展, 允许更复杂的约束形式。广义几何规划可以表示为:

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 1, \quad i = 1, \dots, m \\ & && g_i(x) = 1, \quad i = 1, \dots, p \end{aligned}$$

其中 f_i 是广义正项式, g_i 是广义单项式。

广义单项式: 函数 $g(x)$ 称为广义单项式, 如果它可以表示为:

$$g(x) = cx_1^{a_1} \cdots x_n^{a_n} \prod_{j=1}^m f_j(x)^{b_j}$$

其中 $c > 0$, $a_i \in \mathbb{R}$, $b_j \in \mathbb{R}$, 且 f_j 是正项式。

广义正项式: 广义正项式是广义单项式的和。

广义几何规划也可以通过类似的变量替换和对数变换转换为凸优化问题, 但转换过程可能更复杂。

4.4.6 几何规划的求解方法

几何规划的求解通常包括以下步骤:

1. **问题转换**: 将原始几何规划问题转换为凸形式 - 执行变量替换 $y_i = \log x_i$ - 对目标函数和约束函数应用对数变换 - 验证转换后的函数是凸的
2. **凸优化求解**: 使用凸优化算法求解转换后的问题 - 内点法是求解转换后凸问题的常用方法 - 可以利用转换后问题的特殊结构设计更高效的算法
3. **解的恢复**: 将凸问题的解转换回原始变量空间 - 计算 $x_i^* = e^{y_i^*}$, 其中 y^* 是凸问题的最优解

几何规划问题的求解效率通常很高, 特别是当问题规模不大时。对于大规模几何规划问题, 可能需要使用专门设计的算法。

4.4.7 几何规划与其他优化问题的关系

几何规划与以下优化问题有密切关系:

1. **线性规划**: 几何规划可以看作是线性规划在对数空间中的推广。事实上, 当所有指数 a_{ij} 为零或一, 且所有单项式约束退化为线性约束时, 几何规划退化为线性规划。

2. **对数障碍法**: 在凸优化中, 对数障碍法使用类似几何规划转换中的对数和指数函数来处理不等式约束。

3. **熵最大化**: 某些熵最大化问题可以表示为几何规划问题, 特别是当目标函数是熵函数且约束是线性时。

4. **多项式优化**: 几何规划可以看作是多项式优化的一个特例, 其中变量限制为正, 且系数为正。

4.4.8 几何规划的扩展与变体

1. **分式几何规划**: 目标函数或约束为正项式比值的优化问题

$$\begin{aligned} & \text{minimize} && \frac{f_0(x)}{g_0(x)} \\ & \text{subject to} && \frac{f_i(x)}{g_i(x)} \leq 1, \quad i = 1, \dots, m \\ & && h_i(x) = 1, \quad i = 1, \dots, p \end{aligned}$$

其中 f_i 和 g_i 是正项式, h_i 是单项式。这类问题也可以转换为凸优化问题。

2. **条件几何规划**: 包含逻辑约束的几何规划问题, 例如“如果 $f_1(x) \leq 1$, 则 $f_2(x) \leq 1$ ”。这类问题通常是非凸的, 但可以通过引入二元变量转换为混合整数几何规划。

3. **随机几何规划**: 参数包含不确定性的几何规划问题, 可以通过鲁棒优化或随机规划方法处理。

4.4.9 几何规划的局限性

尽管几何规划有广泛应用, 但它也有一些局限性:

1. **变量必须为正**: 几何规划要求所有变量为正, 这在某些应用中可能是一个限制。
2. **系数必须为正**: 正项式要求所有系数为正, 这限制了可以表示的问题类型。
3. **不能直接处理负项**: 两个正项式的差不能直接表示为正项式, 需要特殊处理。
4. **非凸约束的表示困难**: 某些自然的约束可能难以表示为正项式不等式或单项式等式。

为了克服这些局限性, 研究者提出了各种扩展和变体, 如广义几何规划、符号几何规划等。

4.4.10 几何规划在现代优化中的地位

几何规划在现代优化理论和应用中占有重要地位:

1. **凸优化的桥梁**: 几何规划展示了如何将一类非凸问题转换为凸问题, 这为处理其他非凸问题提供了思路。
2. **工程应用的实用性**: 在许多工程领域, 设计问题自然地表示为几何规划形式, 使得几何规划成为连接理论与实践的桥梁。

3. **优化建模语言的支持：**现代优化建模语言（如 CVXPY、CVX）通常内置对几何规划的支持，允许用户以自然形式表述问题，自动进行转换和求解。

4. **与其他优化方法的结合：**几何规划经常与其他优化方法（如整数规划、随机规划）结合，解决更复杂的问题。

总之，几何规划作为一类特殊的优化问题，通过巧妙的变量替换和函数变换，将非凸问题转化为凸问题，使得许多实际工程设计问题可以高效求解。理解几何规划的原理和应用，对于掌握凸优化理论和解决实际问题都具有重要意义。

Chapter 5

对偶性

Part III

应用

Chapter 6

近似和拟合

Chapter 7

统计估计

Chapter 8

几何问题